قسمت چهارم (بخش دوم)

نقش آمار در روش شناسی علمی (دکتر مسعود محمدی الموتی @)

مقدمه:

- تبدیل مدل‌های ریاضی به مدل‌های آماری برای آزمون پذیر ساختن آنها
- آمار، تحلیل رگرسیونی و آزمون تجربی فرضیه‌ها
- مفهوم آزمون فرضیه (در تحلیل رگرسیونی)

در این قسمت از بحث پیرامون نقش های ریاضیات و آمار در روش شناسی علم بر نقش آمار در این خصوص متمرکز شده و به اجمال و مباحث سه گانه خود را توضیح می‌دهیم.

۱– تبدیل مدل‌های ریاضی به روابط (مدل‌های) آماری:

مدل های ریاضی ،که به شکل توابع ارائه می‌شوند ، اگرچه به ما یک چارچوب تحلیلی برای توضیح رابطه متغیرهای توضیحی با متغیر وابسته ارائه می‌دهند، اما آن را نمی‌توان به عنوان یک حدس برای توضیح واقعیت در نظر گرفت، که بتوان آنرا توسط مشاهدات تجربی آزمون کرد.

پس لازم است تغییراتی در مدل ریاضی (تابع) به وجود آید، که آن را به حدسی قابل آزمایش با مشاهدات تبدیل سازد.

در اینجا است که نقش علم آمار و استنباط آماری-- در قالب تحلیل رگرسیونی-- در روش شناسی علم در کنار نقش ریاضیات، به عنوان چارچوبی تحلیلی برای توضیح ارتباط تغییرات کمی در متغیر وابسته در پی تغییرات کمی در متغیرهای توضیحی، مورد بررسی قرار می‌گیرد.

بنابراین باید توضیحاتی درباره نقش تحلیل آماری در روش شناسی علم-- که وظیفه اصلی آن تبدیل مدل‌های ریاضی به مدلهای آماری و نحوه آزمون فرضیه هایی درباره رابطه بین متغیر وابسته متغیرهای توضیحی در چارچوب مدلهای آماری است- - ارائه گردد.

یک نقش مهم آمار، برای تبدیل مدل ریاضی به رابطه آماری، افزودن یک جمله اختلال به قسمت راست معادله ریاضی(تابع) است.

افزودن این جمله امکان وقوع خطا از نظر شناخت همه متغیرهای توضیحی موثر بر متغیرهای وابسته را وارد مدل ریاضی می کند.

برای مثال اگر معادله ریاضی(۱) را در نظر بگیریم:

$$(1) \qquad Y_t = \propto + \beta X_1 \quad .$$

با افزودن جمله اختلال -- که با U_t نشان داده می شود – به معادله ریاضی (۱) به مدلی آماری (۲) از رابطه بین متغییر توضیحی و متغیر وابسته دست می یابیم:

$$(2) \qquad Y_t = \propto + \beta X_1 + U_t \quad .$$

این مدل آماری می خواهد تغییرات متغیر وابسته Y_t (در طول زمان) در پی تغییرات توضیحی X_i را به کمک پارامترهای مدل(β و $\propto$) و نیز با در نظر گرفتن جمله اختلال (U_t) توضیح دهد.

افزودن جمله اختلال بدان معنی است که: مدل آماری فرض می‌کند که نمی‌توان همه متغیرهای توضیحی ای که در واقع در تبیین تغییرات متغیر وابسته اثر گذار هستند، اما در آن مدل مشخص نشده‌اند را به گونه ای در نظر گرفت. در نتیجه مدل آماری عوامل پیش بینی نشده را به عنوان غیرقابل پیش‌بینی و تصادفی وارد مدل کرده و انرا به حدسی قابل ازمون تبدیل می شود.

افزودن جمله اختلال به عنوان خطای تصادفی مدل این امکان را به وجـود مـی‌آورد که این مدل آماری را به عنوان حدسی که امکان خطا در آن وجود دارد نگاه کنیم. رابطه ای که باید آن را با شواهد آماری (مشاهدات) مورد آزمون قرار دهیم. بدین ترتیب مـدل آماری به حدسی قابل سنجش با مشاهدات تجربی تبدیل می شود.

البته همانطوری که در ادامه ملاحظـه خـواهیم کـرد ایـن حـدس در واقـع دربـاره پارامترهای مدل یعنی ضرایب β و α زده می‌شود و نـه مسـتقیما دربـاره متغیرهـای توضیحی اثر گذار بر متغیر وابسته و از طریق طرح فرضیه‌هایی در مـورد آن پارامترهـا ، مانندپارامتر β ، میتوان دید که آیا مشاهدات رابطه آماری معنی‌داری را بین متغیرهـای توضیحی X_t و متغیر وابسته Y_t تایید می کنند یا نه؟

۲- آمار ، تحلیل رگرسیونی و آزمون تجربی فرضیه ها

در این قسمت مقدمات تحلیل آماری را برای نشان دادن آنکه چگونه فرضیه‌هایی در مورد نقش متغیرهای توضیحی در تبیین متغیر وابسته ارائه می‌گردند مطرح می شود.

قبل از آنکه بخواهیم به بحث اصلی در مورد اینکه علم آمار چگونه به روش شناسی علم تجربی در زمینه آزمون فرضیه‌ها کمک اساسی کرده است باید توضیحاتی را در مورد تحلیل رگرسیونی، که مرتبط با فروضی در مورد ویژگی‌های جمله اختلال و پیامدهای آن برای ویژگی‌های متغیر وابسته و کل مدل آماری ارائه کنیم.

در واقع این توضیحاتی اجمالی در مورد تحلیل رگرسیونی است که پایه های لازم برای درک مفهوم آزمون فرضیه و نقش اساسی آن در روش شناسی علم را فراهم می آورد.

در کتاب **اقتصاد سنجی** (جلد اول) مسعود درخشان (۱۳۷۴:۱۶) چنین می‌آید:

تفاوت کلی مدل های ریاضی و مدل های رگرسیونی در جمله اختلال است. هر گاه به مدل های ریاضی یک جمله اختلال که یقیناً تصادفی است، اضافه کنیم مدل ریاضی به مدل رگرسیونی تبدیل خواهد شد.

در مدل رگرسیونی یاد شده $Y_t = \propto + \beta X_t + U_t$ ، β و $\propto$ پارامترهای مدل هستند که مقادیر واقعی آنها را نمی‌دانیم .

بنابر این در قالب تحلیل رگرسیونی سعی می‌کنیم مقادیر آنها را برآورد کنیم. بدین ترتیب یکی از وظایف اصلی تحلیل رگرسیونی تخمین پارامترهای مدل رگرسیون است.

بدست آوردن فرمول‌های تخمین زننده پارامترهای مدل رگرسیونی از جمله اهداف اصلی تحلیل رگرسیونی است. بدین منظور فرایندهای زیر طی می‌شود.

به منظور درک خصوصیات مدل رگرسیونی و نتایج آنها برای بدست آوردن تخمین زننده های پارامترهای مدل بحث را از خصوصیات آماری جز یا جمله یا جمله اختلال (U) آغاز می کنیم.

در اینجا هدف ورود تفصیلی بر خصوصیات جمله اختلال-- آنگونه که تحت عنوان فروض مربوط بـه جمله اختلال در روش حداقل مربعات معمولی ols مطرح میگردد-- نیست.

بلکه هدف اشاره ای به کاربرد آن فروض در بدست آوردن تخمین زننده های پارامترهای مـدل ماننـد پارامتر β -- که ضریب متغیرهای توضیحی مدل می‌باشد -- خواهد بود.

فروض ols در مورد خصوصیات متغیر تصادفی (U_t) -- که همان جمله اخـتلال در مـدل رگرسـیونی است -- نشان می‌دهد که تابع توزیع U دارای امید به ریاضی صفر واریانس ($Б^2$) ثابتی است.

این خصوصیات توزیع جمله اختلال را به شکل زیر نشان می‌دهد:

$$U_t \sim IN\ (0\ ,Б^2)$$

نکته مهم در اینجا آنستکه وقتی جمله اختلال (U) دارای خصوصیات یک متغیر تصادفی با توزیع فوق است - از آنجاییکه آن جمله بخشی از طرف راست معادله رگرسیونی را تشکیل می دهد -- طرف چپ معادله -- یعنی متغیر وابسته -- هم به طور طبیعی از خصوصیات یک متغیر تصادفی برخوردار خواهد شد. بدین ترتیب می توان خصوصیات آماری کل مدل رگرسیونی را بدست آورد.

شایان ذکر است در روش حداقل مربعات معمولی (ols) هدف برآورد مناسب پارامترهای مدل (β و $\propto$) بگونه ای است که بتوان مشاهدات را در چارچوب فرمول‌های تخمین زننده‌های آنها ($\hat{\beta}$ و $\hat{\propto}$) قرار داد.

سپس بر اساس آن برآورد ها بتوان فرضیه‌هایی در مورد ضرایب مدل رگرسیونی (مثال فرضیه‌های H_0 و H_1 را در مورد ضریب β) را مورد آزمون آماری قرار داد.

مسئله اساسی آنستکه : چگونه میتوان از مشاهدات برای تخمین پارامترها ($\hat{\beta}$ و $\hat{\propto}$) استفاده کرد.

در اینجاست که تحلیل رگرسیونی به کمک ما آمده و نشان میدهد که چگونـه براسـاس خصوصـیات آماری مدل رگرسیونی میتوان به فرمولهای تخمین زننده های $\propto$ و β دست یافت که آنها را با نمادهای ($\hat{\beta}$ و $\hat{\propto}$) نشان می دهیم.

برای آنکه خصوصیات مدل رگرسیونی را بدست آوریم چنین بحث میشود که اگر U_t در رابطه زیـر دارای خصوصیات تصادفی است پس Y_t (متغیر وابسته) هم دارای خصوصیات متغیر تصادفی خواهد بود.

$$1. \quad Y_t = \propto + \beta X_t + U_t \quad .$$

چون U_t دارای امید به ریاضی و واریانس $Б^2$ است پس برای Y_t هم این خصوصیات جاری و ساری است:

امید به ریاضی Y_t به ترتیب زیر ارائه می گردد:

$$E(\beta X_t) = \beta E(X_t) = \beta X_t$$

چون مطابق فروض ols $E(U_t)=0$ است. پس رابطه (۲) خواهیم داشت:

$$2. \quad E(Y_t) = \propto + \beta X_t \quad .$$

در تحلیل رگرسیونی، رابطه (۲) تابع رگرسیونی جامعه نامیده میشود که رابطه آماری بین متغیرهای توضیحی مدل و متغیر وابسته آنرا با توجه به پارامترهای مدل برقرار کرده است.

حال اگر بجای $\propto$و β (پارامترهای واقعی جامعه) برآورد های آنها را -- یعنی $\hat{\beta}$ و $\hat{\propto}$ -- را قرار دهیم به تابع رگرسیون نمونه دست پیدا می کنیم.

$$3. \quad E(\hat{Y}) = \hat{\propto} + \hat{\beta}\ X_t \quad .$$

اما برای محاسبه $\hat{\beta}$ و $\hat{\alpha}$ براساس مشاهدات و استفاده از مقادیر آنها برای آزمون فرضیه های H_0 و H_1 در مورد این پارامترها باید ابتدا به کمک روش حداقل مربعات معمولی (ols) فرمول های تخمین زننده های این پارامترها را بدست آورد.

برای مثال ، اشاره ای به نحوه بدست آوردن فرمول تخمین زننده $\hat{\beta}$ که آنرا $\hat{\beta}_{ols}$ می خوانیم، خواهیم داشت. منطق های روش ols برای به دست آوردن فرمول $\hat{\beta}_{ols}$ را میتوان به طور خلاصه (درخشان: صفحات ۲۸ تا ۳۴) به شرح زیر توضیح داد :

میتوان تابع رگرسیون جامعه $Y_t = \alpha + \beta X_t + U_t$ را به کمک تابع دیگر، یعنی رگرسیون نمونه $\hat{Y}_t = \hat{\alpha} + \hat{\beta} X_t$ چنان برآورد کرد که مقادیر ($\hat{\alpha}$ و $\hat{\beta}$) آن مقادیری را داشته باشند که تابع رگرسیون نمونه -- نسبت به هر مدل خطی دیگر -- بیشترین نزدیکی را با مشاهدات داشته باشد.

از آنجایی که خطای مدل رگرسیونی ، در روش ols در قالب جمله اختلال (U_t) تعریف شده که خود ماهیتی تصادفی دارد، این امکان برای روش مذکور فراهم می‌آید که چنین استدلال کند:

تنها وقتی می‌توان از مشاهدات برای تخمین مدل رگرسیونی مورد نظر استفاده کرد که:

خطا یا انحراف از آنچه مقدار واقعی Y_t (در تابع رگرسیونی جامعه) است با آنچه برآورد آن می باشد (یعنی $\hat{Y}_t$، در تابع رگرسیون نمونه) حداقل باشد. در واقع با یک برداشت تصادفی از خطای مشاهدات است که می‌توان منطق درونی روش حداقل مربعات معمولی (ols) را درک کرد.

روش (ols) روشی است که می‌خواهد خطاهای تصادفی مشاهدات را حداقل کند. تا برآورد $\hat{Y}$ حداقل خطا را نسبت به واقعیت Y_t داشته باشد. در این روش حداقل سازی خطای مشاهدات از طریق حداقل کردن رابطه زیر جستجو می شود.

$$e_t = Y_t - \hat{Y}_t \quad .$$

به e_t جمله پسماند می گویند.

برای مثال برای حداقل کردن آن باید $\hat{\beta}$ را چنان برآورد کرد که مجموع جملات پسماند $\sum e_t^2$ به حداقل برسد. اما چرا "مجموع" مربعات را [در روش حداقل مربعات معمولی ols] باید حداقل کرد؟

دلیل آنستکه روش ols در پی آنستکه نه تنها انحراف های + و - یکدیگر را خنثی نکنند، بلکه تخمین $\hat{\beta}$ به گونه‌ای صورت گیرد که **خطاهای بزرگتر نسبت به خطاهای کوچکتراز اهمیت بیشتری** برخوردار باشند:

می دانیم که $\sum_i^n e_t^2$ برابر است با:

$$4. \quad \sum_i^n e_t^2 = \sum_i^n \left(Y_t - \hat{Y}_t\right)^2 = \sum (Y_t - \hat{\propto} - \hat{\beta} X_t)^2$$

بنابراین، مسئله تخمین αو β به مسئله حداقل سازی رابطه فوق نسبت به $(\hat{\beta}$ و $\hat{\alpha})$ تبدیل می‌شود.

فرمولهای تخمین زننده های $(\hat{\beta}$ و $\hat{\alpha})$ از طریق مشتق گرفتن از رابطه (۴) ($\hat{\beta}_{ols}$ و $\hat{\alpha}_{ols}$) نسبت به $(\hat{\beta}$ و $\hat{\alpha})$ بدست می آید.

برای مثال ، فرمول $\hat{\beta}_{ols}$ به ترتیب زیر بدست می آید:

$$\frac{\delta \sum e_t^2}{\delta \hat{\beta}} = \frac{\delta \sum (Y_t - \hat{\alpha} - \hat{\beta} X_t)^2}{\delta \hat{\beta}} = 0$$

$$= 2\sum (Y_t - \hat{\alpha} - \hat{\beta} X_t)(-X_t) = 0$$

$$= 2\sum (Y_t - \hat{\alpha} - \hat{\beta} X_t)(X_t) = 0$$

در نهایت فرمول تخمین زننده $\hat{\beta}$ به شرح زیر بدست می آید:

$$\hat{\beta}_{ols} = \frac{\sum X_t + Y_t}{\sum x_t^2} \quad .$$

وقتی فرمول $\hat{\beta}_{ols}$ به ترتیب فوق بدست آمد، هنگامی که مشاهدات در آن فرمول قرار داده می شوند ، مشاهدات مربوط به X_t و Y_t (متغیرهای توضیحی و وابسته) مدل رگرسیونی فرضیه برای یک آزمون آماری فرضیه فراهم می آید.

۳- مفهوم آزمون فرضیه در تحلیل رگرسیونی

اکنون نوبت به آن می‌رسد که نقش علم آمار -- به ویژه نقش تحلیل رگرسیونی در آزمون تجربی یک فرضیه علمی، که برای روش شناسی علمی دارای اهمیت اساسی است -- را به اجمال توضیح دهیم.

بدین منظور ابتدا باید یادآوری کرد که فرضیه‌های علمی به عنوان حدس های ابطال پذیر در چارچوب تحلیل رگرسیونی در قالب فرضیه های H_0 و H_1 درباره پارامترهای مدل رگرسیونی ارائه می گردند و کارکرد آنها این است که نشان دهند برای مثال در قالب فرضیه‌هایی درباره مقدار واقعی β (پارامتر واقعی تابع رگرسیون جامعه) ، آیا مشاهدات $\hat{\beta}$ آن فرضیه ها را رد یا تایید می‌کند؟

فرضیه H_0 ، که آنرا فرضیه پوچ هم می‌خوانند، حاکی از آن است که β صفر فرض شده است: و فرضیه H_1 (به عنوان فرضیه آلترناتیو) در وضعیت کاملاً مخالف با آن قرار دارد به همین خاطر یعنی β نامساوی صفر است.

$$H_0 : = \beta\ 0 \qquad \text{و} \qquad H_1 : \beta \neq 0$$

این دو فرضیه این چنین تعریف شده‌اند برای آنکه اگر فرضیه H_0 رد یا تایید شد ، حالت منطقی مقابل آن تایید یا رد شدن فرضیه H_1 باشد.

در واقع فرضیه اصلی تحقیق، فرضیه H_1 است، چرا که عدم مساوی بودن آن با صفر ($H_1: \beta \neq 0$) بدان معنی است که β به عنوان ضریب متغیر توضیحی X_t صفر نبوده و می تواند نشانگر رابطه معنی داری بین X_t (به عنوان متغیر توضیحی مدل رگرسیونی) و Y_t (به عنوان متغیر وابسته مدل رگرسیونی) باشد.

در مقابل، اگر فرضیه H_0 ($\beta=0$) تایید شود، بدان معنی خواهد بود که X_t بعنوان یک متغیر توضیحی اثر معنی داری بر Y_t به عنوان متغیر وابسته نداشته است.

با توجه به این توضیحات، ابتدا باید دید اساساً مفهوم آزمون فرضیه در تحلیل رگرسیونی چیست؟

در پاسخ به این سوال باید گفت که در نگاه اولیه آن است که آیا مشاهدات $\hat{\beta}$ فرضیه H_0 در مـورد β (پارامتر واقعی جامعه مورد نظر) را تایید کرده و یا آنرا رد می‌کنند؟ اما وقتی بطور دقیق تر به تفسیر مفهوم آزمون فرضیه در تحلیل رگرسیونی نگاه می کنیم، متوجه مـی شـویم کـه هـدف اصـلی از آزمـون فرضیه آنستکه نشان دهد که آیا:

$\hat{\beta}$ ، به عنوان مشاهدات تخمین زده شده به جامعه‌ای که میانگین آن β (یعنی واقعیتی که فرضیهای H_0 و H_1 در مورد آن مطرح شده اند) تعلق دارد یا نه ؟

با این توضیح از رویکردی که تحلیل رگرسیونی به مفهوم آزمون فرضیه (H_0و H_1) دارد، اکنون به کمک توضیح سه مبحث زیر این مفهوم و نقش آن در روش شناسی علم را مورد بررسی قرار می‌دهیم.

1) توضیحاتی در مورد نقش جدول Z (یا Z جدول) در آزمون فرضیه

2) توضیحاتی در مورد Z (Z_c) محاسباتی و نقش آنها در آزمون فرضیه

3) توضیحاتی در مورد نقاط بحرانی a و b و نقش آنها در آزمون فرضیه

۳–۱ نقش جدول Z (یا Z جدول) در آزمون آماری فرضیه

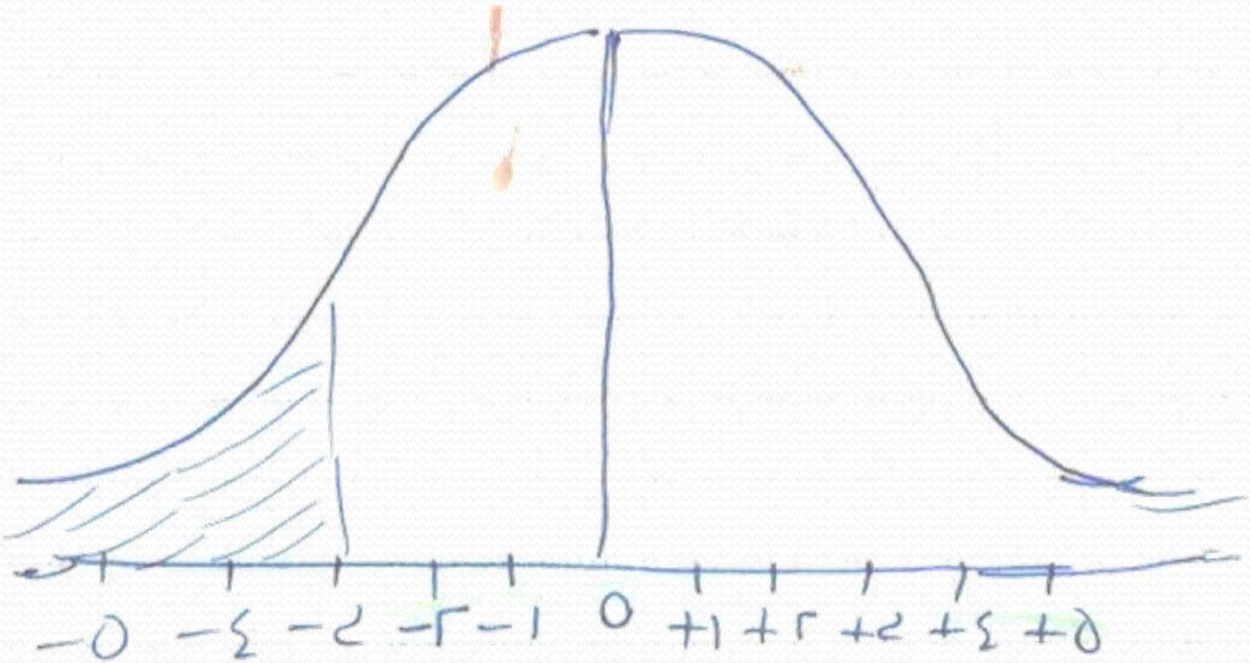
ابتدا به خاطر داشت که هرگاه تابع توزیع $\hat{\beta}$ نرمال باشد، می توان برای آزمون فرضیه ای درباره β از آزمون آماری Z استفاده کرد، یعنی جایی که واریانس جمله اختلال ($ver(U_t) = Б_u^2$) را می دانیم.

با توجه به این نکته، برای اینکه نقش جدول Z و نیز Z جدول را در آزمون آماری فرضیه توضیح دهیم، باید این نکته را توضیح داد که یک توزیع نرمال استاندارد چیست؟

در پاسخ به این سوال باید گفت که، توزیع مذکور، توزیعی است که دارای میانگین صفر و واریانس ۱ است. این بدان معنی است که مرکزیت این توزیع صفر بوده و پراکندگی توزیع در اطراف آن مرکز با انحراف معیارهای یکسانی صورت گرفته است و در دو طرف آن مرکز قرار گرفته اند.

نمودار (۱) مفهوم توزیع نرمال استاندارد را نشان می‌دهد.

نمودار شماره ۱



هر عدد روی محور افقی نمودار (۱) مرتبط است با یک Z_{Score} که به ما مـی گویـد چنـد انحـراف معیار (SE) در مشاهدات نسبت به جامعه (μ) وجود دارند.

برای مثال ، Z_{Score} مساوی ۲- می‌گوید که ۲ انحراف معیار از میانه در طـرف چـپ نمـودار وجـود دارند و Z_{Score} مساوی ۲+ می‌گوید که دو انحراف معیار از میانه در طرف راست نمودار وجود دارند. نکته بسیار مهم آن است که

Z_{Score} به ما اجازه می‌دهد که مشخص کنیم، چه مقدار از مناطق زیر منحنی در نمودار (۱) با آن اندازه (مقدار Z) مرتبط است.

برای مشخص کردن آنکه این مناطق دقیقاً چقدر است از جدول Z استفاده می‌کنیم.

در اینجا است که به نقش جدول Z و Z جدول در آزمون آمار فرضیه می‌توان پی برد.

جدول Z که اندازه‌های مرتبط با سطوح زیر منحنی در آن محاسبه شده‌اند، به ما می‌گوید که در نقطه Z بروی محور افقی در نمودار (۱) سطح زیر منحنی در طرف چپ مقدار Z چقدر است؟

نقاط بحرانی a و b -- وقتی مقدار $\hat{\beta}$ در آن مناطق بحرانی قرار گیرد، فرضیه H_0 در مورد β تایید نخواهد شد -- از طریق انتگرال گیری از تابع توزیع نرمال استاندارد به دست می‌آیند.

برخلاف گذشته لازم نیست برای هر مسئله‌ای جداگانه انتگرال گیری شود، چون فقط یک تابع برای منحنی نرمال استاندارد وجود دارد. با توجه به اینکه میانگین و واریانس آن تابع همواره صفر و یک هستند، کافی است که به ازای مقادیر مختلف موجود روی محور Z (در نمودار ۱) ، انتگرال‌گیری شود و سطوح مختلف زیر منحنی نرمال استاندارد را محاسبه کرد.

جدول Z در واقع حاوی این محاسبات است.

بدین ترتیب می توانیم به کمک جدول Z برای هر نقطه روی محور افقی Z یک سطح زیر منحنی را نسبت به طرف چپ آن محاسبه کرد.

آنچه برای آزمون آماری فرضیه علمی به کمک استانداردسازی تابع توزیع نرمال دارای اهمیت است:

هر نوع توزیع نرمالی -- با هر مقداری از میانگین و انحراف معیار-- قابلیت تبدیل شدن به توزیع نرمال استاندارد را دارد. یعنی می‌توان با استاندارد سازی، امید ریاضی و انحراف معیار آن توزیع نرمال را به صفر و یک تبدیل کرد.

فرایند استاندارد سازی از طریق فرمول زیر انجام می‌شود:

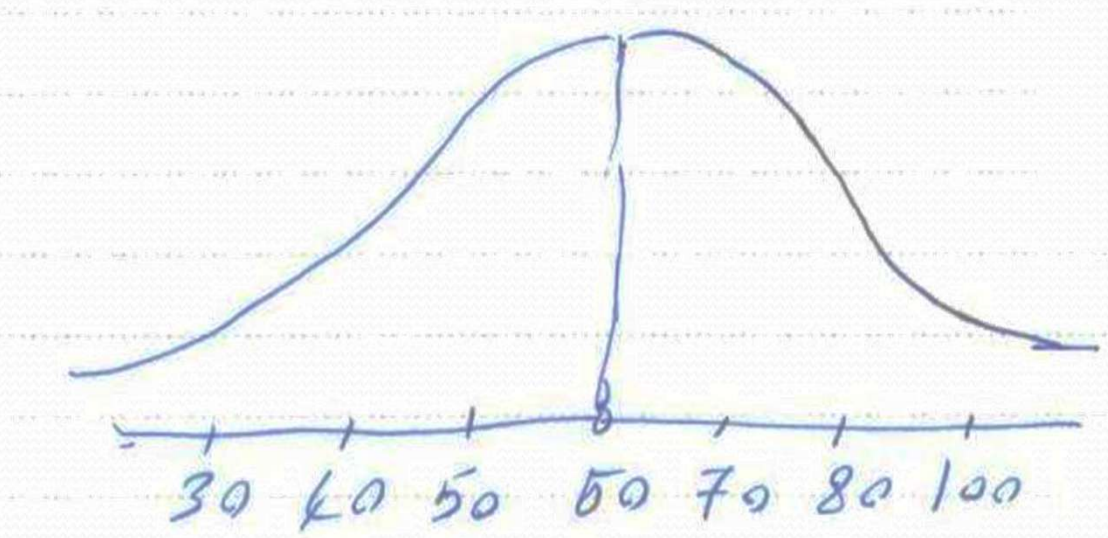
$$Z = \frac{\text{X} - \mu}{\text{Б}^2}$$

$$Z^{score} = \frac{X^{observation} - \mu^{Dopulation-mean}}{\text{Б}_{pobulation}\, SE}$$

برای مثال:

فرض کنیم که توزیع نرمالی در نمودار(۲) نشان داده شده دارای میانه ۶۰ و انحراف معیار ۱۰ است.

نمودار شماره ۲



به منظور تبدیل این توزیع نرمال به یک توزیع نرمال استاندارد با میانه صفر و واریـانس ۱ از فرمـول فوق استفاده می کنیم و با جایگذاری میانه و انحراف معیار در آن خواهیم دانشت.

$$Z = \frac{X - 50}{10}$$

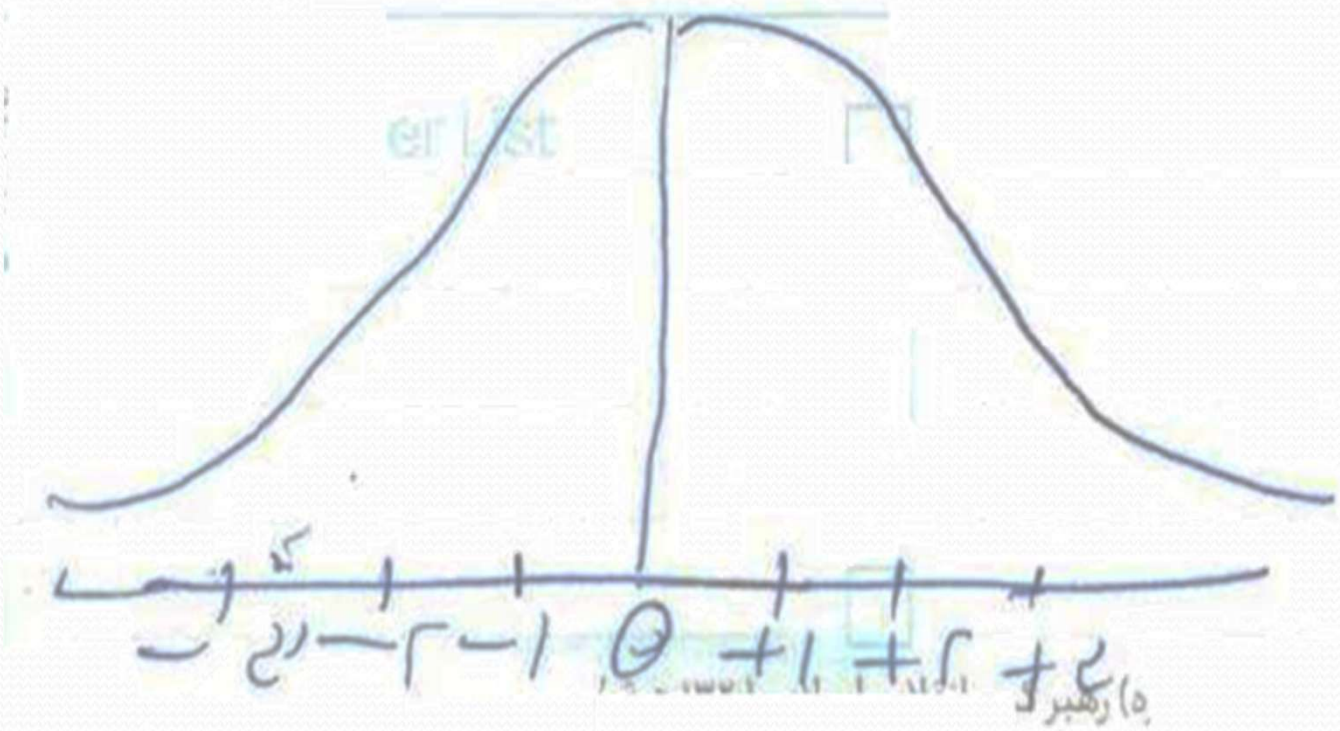
حال از طریق جایگذاری مقادیر روی محور Z در فرمول یاد شده به یک Z نرمال استاندارد می‌رسیم کـه در نمودار (۳) نشان داده شده است. اگر مقدار ۶۰ را در فرمول فوق قرار دهیم Z می‌شود صفر .

$$Z = \frac{60 - 50}{10} = 0$$

(میانه توزیع نرمال استاندارد)

و همینطور اگر ۵۰ را در آن فرمول قرار دهیم Z می شود ۱- و الی آخر.

نمودار شماره ۳



اتفاقی که با تبدیل یک توزیع نرمال خاص به توزیع نرمال استاندارد می‌افتد آن است که : آن متغیر تصادفی که یک چنان توزیع نرمال خاصی را دارد به متغیری استاندارد -- با میانه صفر و واریانس یک -- تبدیل می گردد. بدین ترتیب تبدیل تابع توزیع نرمال یک متغیر تصادفی به تابع توزیع نرمال استاندارد آن متغیر، امکان مقایسه متغیر تصادفی $\hat{\beta}$ استاندارد شده را با مقادیر Z جدول فراهم می‌آورد.

همچنین این امکان به وجود می‌آید که در فرایند آزمون فرضیه تعلق $\hat{\beta}$ (با تابع توزیع نرمال استاندارد شده) به میانگین جامعه ای که β است را نشان داد. چون تابع توزیع نرمال هر دو دارای میانگین صفر و واریانس یک هستند.

بنابراین ، وقتی که یک متغیر تصادفی مانند $\hat{\beta}_{ols}$ ، که دارای توزیع نرمال است استاندارد می‌شود -- با هر میانه و انحراف معیاری ای-- میانه (μ) و انحراف معیار آن [SE](Б) آن به ترتیب صفر و یک خواهند بود.

بدون چنین یکسان سازی ای ، نمی‌توان نشان داد که آیا $\hat{\beta}_{ols}$ به جامعه ای تعلق دارد که میانگین آن β باشد و در نتیجه فرضیه‌های H_o و H_1 در مورد آزمون میانگین $\hat{\beta}$ بر اساس مشاهدات یعنی $\hat{\beta}_{ols}$ قابل آزمون تجربی نخواهند بود.

۳– ۲ نقش جدول Z (یا Z جدول) در آزمون آماری فرضیه

مفهوم Z_C (Z محاسباتی) را می‌توان به شرح زیر ارائه کرد:

$$Z_c = \frac{\overline{X} - \mu 0}{Б/\sqrt{\mu}}$$

جایی که : ارزش فرضی میانه = μ_0 و میانه جمعیت = μ_1

حال اگر ارزش فرضی میانه (یعنی μ_0) مورد نظر را در فرمول فوق قرار دهیم، می‌توانیم ارزشی برای Z محاسبه کنیم که Z_C یا Z محاسباتی نامیده می‌شود.

این Z_C در واقع همان آماره آزمون Z است که برای تست فرضیه ای -- برای مثال در مورد β (پارامتر واقعی جامعه) از طریق $\hat{\beta}_{ols}$ -- آن ملاک آزمون آماری ما خواهد بود.

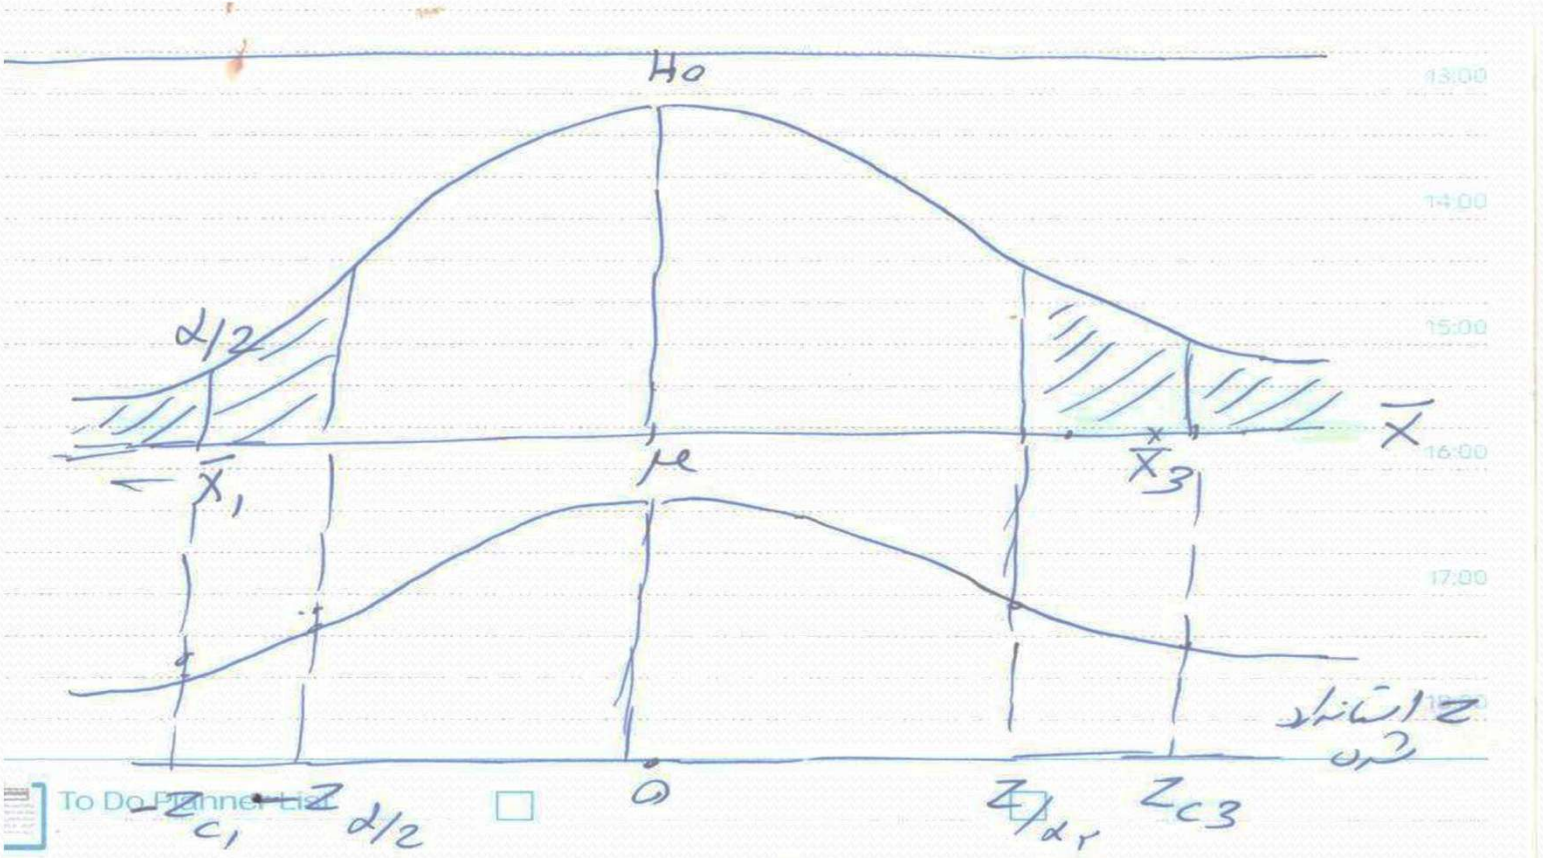
از مفهوم آزمون آماری فرضیه، به خاطر داریم که فرضیه H_0 در مورد β است، حال می خـواهیم بـه کمک $\hat{\beta}_{ols}$ و ملاک آزمون Z (یعنی محاسبه Z_C) این مسئله اساسی را بررسی کنیم که:

آیا فرضیه H_0 $(\beta=0)$ به جامعه‌ای که میانه آن β است تعلق دارد یا نه؟ و ایـن کـار را از طریـق مقایسه Z جدول مرتبط با آن $\hat{\beta}$ و جایگذاری $\hat{\beta}_{ols}$ در ملاک آزمون Z یعنی مقایسه Zجدول آن بـا Z محاسباتی اش انجام می‌دهیم.

در قالب نمودارهای (۴) و (۵) می‌توان مفهوم آزمـون فرضـی در تحلیـل رگرسـیونی را بـا توجـه بـه توضیحاتی که در مورد Zجدول و Z محاسباتی داده شد درک کرد.

نمودار (۴) تصویری از چگونگی مقایسه بین Z جدول و Z محاسباتی برای آزمون فرضیه H_o در باره β ($H_o: \beta=o$) به کمک مشاهدات $\hat{\beta}_{ols}$ ارائه می کند.

نمودار شماره ۴



در این حالت فرضیه H_0 تایید نشده چون $\bar{X}_3$ و $\bar{X}_1$ در مناطق بحرانی قرار گرفته اند.

در نمودار (۴) قسمت بالایی نمودار توزیع احتمال فرضیه H_0 را با میانه μ نشان می دهد.

علت آنکه آنکه آن قسمت با قسمت پایینی نمودار مذکور قابل مقایسه شده آن استکه، قسمت پایینی حاوی Z استاندارد شده، یعنی آن هم تابع توزیع احتمالی برابر با میانگین صفر و واریانس ۱ دارد.

در این حالت ، وقتی که Z_C در نقاط بحرانی که با $\pm Z \propto/2$ مشخص شده‌اند قرار می‌گیرد بیانگر آن خواهد بود که $\hat{\beta}_{ols}$ (برآورد مشاهدات) به جامعی که میانگین آن β است تعلق ندارد.

این معنای ابطال فرضیه H_0 است در مورد ($\beta=0$) می باشد و تایید فرضیه H_1 ($\beta\neq 0$)

می توان نتیجه گرفت که X_t با ضریب β بر تغییرات Y_t (متغیر وابسته) در مدل رگرسیونی اثر معنی داری داشته است.

همانطورکه نمودار (۴) نشان میدهد: مقایسه $\overline{X}$ ها ($\overline{X_1}$ و $\overline{X_3}$) با به ترتیب $-Z_C1$ و $+Z_C2$ صورت گرفته و نشان داده که آنها عملا در نقاط بحرانی (هاشور خورده) قرار گرفته اند.

<u>این واقع شدن $\overline{X}$ ها در نقاط بحرانی علامت روشنی برای ابطال فرضیه H_0 است و سپس می توان گفت که فرضیه H_1 رد نشده یا تایید شده است.</u>

یادآوری می‌شود که برای هر $\overline{X}$ یک نقطه مرتبط Z_C وجود دارد که با قرار دادن μ_0 در فرمول Z_C یا آماره آزمون Z به دست می‌آید. در نمودار شماره(۴) این Z محاسبه شده چیزی بیش از تعداد انحراف معیارهایی نیست که میانه فرض شده μ_0 از میانه نمونه μ دارد.

به بیان دیگر اگر میانه نمونه (μ_0) که از مشاهدات به دست می‌آید، در میان تعداد زیادی از انحراف معیارها نسبت به میانه فرضیه β یعنی $\hat{\mu}$ جامعه قرار داشته باشد. **<u>آن نمی‌تواند از توزیعی آمده باشد که میانه فرض شده (یعنی β) از آن توزیع آمده است.</u>**

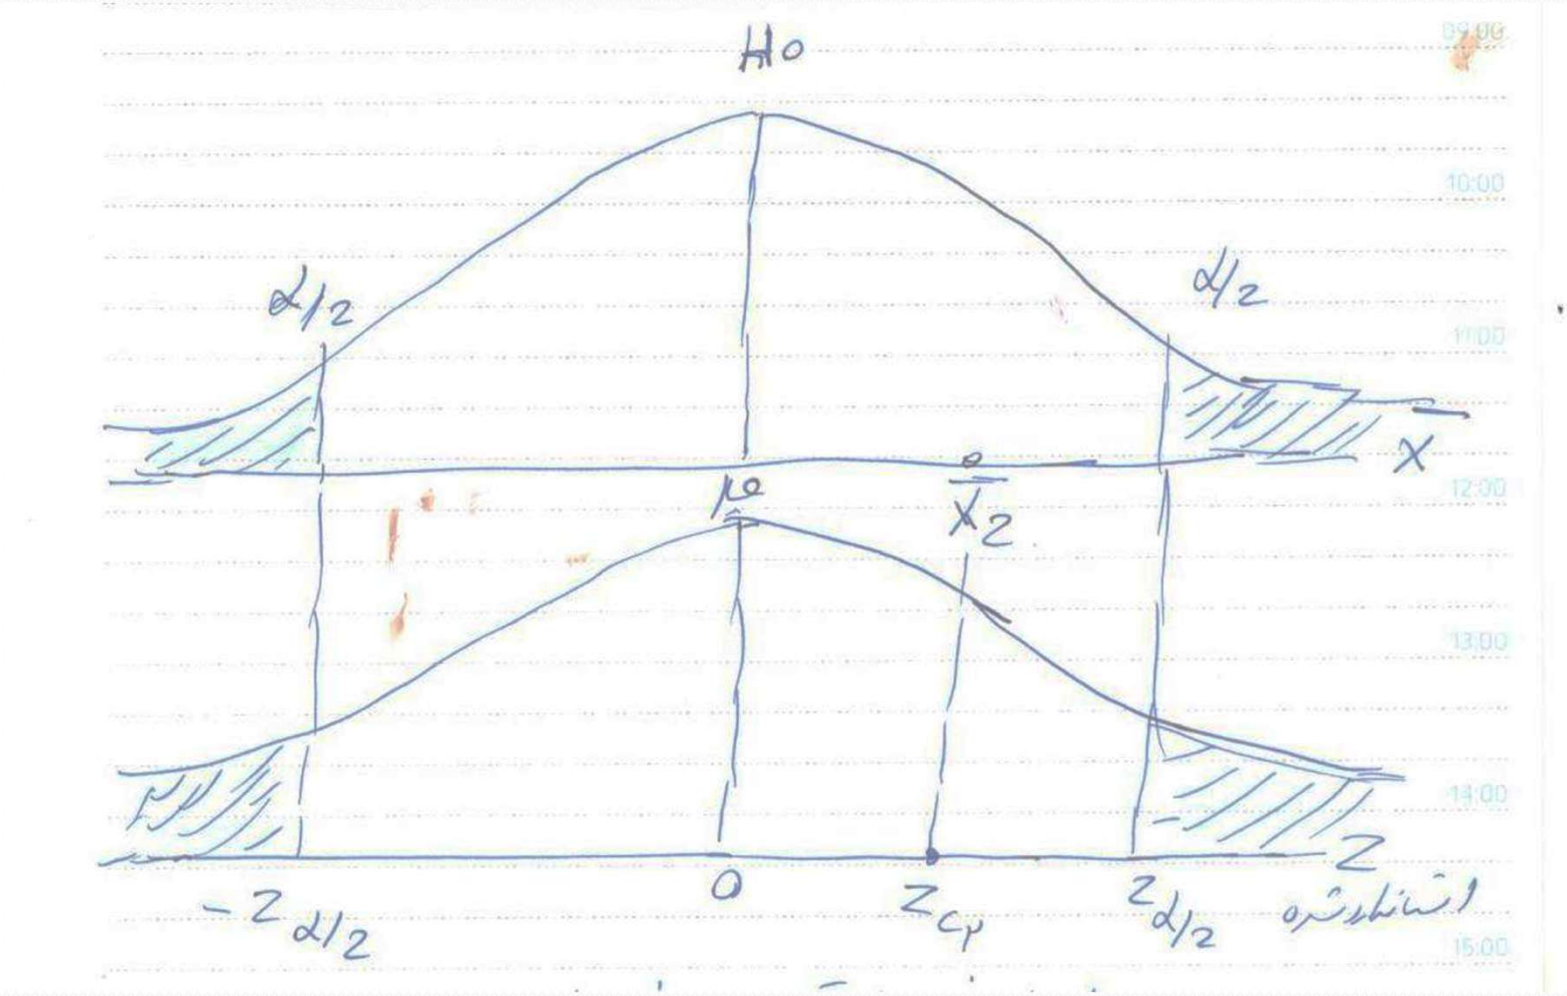
با داده بودن سطوح معنی‌داری (یا فاصله اعتماد) که در ادامه بـه آن اشـاره مـی‌کنـیم ، مـی‌تـوان فرضیه H_0 را بر اساس مشاهدات آزمون کرده و آن را ابطال یا تایید نمود.

اکنون می توان در نمودار (۵) به حـالتی توجـه کنـیم کـه در آن فرضـیه H_0 ($\beta = 0$) از طریـق مراجعه به مشاهدات تایید می‌گردد و در واقع باید گفت فرضیه H_1 ($\beta \neq 0$) رد شده است .

ن مودار (۵) حاکی از آن است که $\overline{X}$ مورد نظر در نقاط بحرانی قرار نگرفته و این بدان معنی اسـت که $\hat{\beta}_{ols}$ و میانه مرتبط با آن μ_0 از جامعه ای می آید که میانه آن β است.

<u>پس میتوان گفت فرضیه H_0 با مشاهدات تایید شده و یا رد نشده است.</u>

نمودار شماره ۵



در اینجا فرضیه H_0 تایید و فرضیه H_1 رد می شود.

این نمودار نشان می‌دهد که : $\bar{X}_2$ که قابل مقایسه با Z_{C2} است در نواحی بحرانی در دو طرف تابع توزیعی احتمال استاندارد که با هاشور مشخص شده‌اند قرار نگرفته است.

پس مطابق استدلال‌های قبلی فرضیه H_0 به کمک مشاهدات مربوط به $\hat{\beta}_{ols}$ رد نشده و در واقع این فرضیه $\beta \neq 0$: H_1 ابطال می شود، این بدان معنی است که وقتی پارامتر β صفر باشد متغیر توضیحی X_t نمی تواند اثر معنی داری بر تغییرات Y_t (متغیر وابسته) داشته باشد .

اکنون که مفهوم آزمون فرضیه (در دو حالت که در آمار از آنها فرضیه H_0 رد می شود و در دیگر آن فرضیه تایید می شود) و روش‌هایی که برای آزمون آماری یک فرضیه علمی توضیح داده شد، در پایان اشاره ای باید به اینکه نقاط بحرانی a و b روی نمودارهای مربوط به آزمون فرضیه چگونه انتخاب می‌شوند؟ داشته باشیم.

همانطوریکه درخشان (۱۳۷۴) می گوید:

از آنجاییکه مدل رگرسیون دارای خطای تصادفی است و این خطا باید در شیوه آزمون در نظر گرفته شود وقتیگفته می‌شود با احتمال ۹۵ در صد یک فرضیه را آزمون می‌کنیم، نقاط بحرانی (مانند a و b) را که -- فرو افتادن مشاهدات در آنها باعث ابطال فرضیه و عدم واقع شدن مشاهدات در آنها باعث عدم ابطال فرضیه می گردد -- خود باید با توجه به آن درصد (فاصله اطمینان)، تعیین شوند.

نقاط بحرانی (a و b) -- که برای آزمون فرضیه اهمیت اساسی دارند– تعیین می شوند؟

این سوال مهمی است **چون نقاط بحرانی و مناطق مربوط به آنها که با سطح زیر منحنی هاشور خورده در نمودارهای (۴) و (۵) نشان داده شده اند هستند** که زمینه ابطال یا تایید فرضیه H_0 را بوجود می آورند.

یک مثال

در یک آزمون دو طرفه که نقاط بحرانی a و b در دو سوی منحنی توزیعی نرمال قرار گرفته است، فاصله اعتماد ۹۵ درصد به این معنی است که باید ۹۵ درصد سطح زیر منحنی توزیع احتمال حول محور مرکزی قرار داشته باشد.

در واقع آن سطح ۹۵ درصدی است که نقاط a و b را به عنوان نقاط بحرانی مشخص می کند.

اگر $\hat{\beta}_{ols}$ به دست آمده از نمونه در فاصله a و b قرار گیرد ، این نمونه متعلق به جامعه‌ای است که میانه آن β نخواهد بود.

به فاصله a و b **فاصله اعتماد یا فاصله اطمینان** گفته می شود و نواحی خارج از این فاصله زیر منحنی توزیع احتمال ، ناحیه بحرانی نامیده می‌شود.

برای یافتن این نقاط، کافی است از تابع توزیع احتمال $\hat{\beta}$ انتگرال گرفته شود و دو نقطه را روی محور $\hat{\beta}$ آنچنان تعیین کنیم که سطح زیر منحنی حول محور مرکزی برابر با ۹۵ درصد گردد.

با تعیین این نقاط (a و b) نواحی بحرانی و نیز فاصله اعتماد مشخص می‌گردد.

نمودار شماره ۶ - فاصله اطمینان

